ChargeWise AI - Evolução Sprint 04

1. Resumo da evolução

O projeto evoluiu do chatbot de terminal com contexto simulado, Ollama/LangChain, schema Pydantic e memória para recuperação documental com embeddings Nomic, Chroma persistente, fontes visíveis e interface Streamlit. A comparação operacional atual está em docs/comparativo_operacional.md; a referência manual foi reexecutada, não recuperada como medição histórica. Na tabela abaixo, N/D identifica medições originais indisponíveis, sem estimativas inventadas.

2. Pipeline e decisões

PyMuPDFLoader lê PDFs inventariados; Markdown é separado por seção. RecursiveCharacterTextSplitter usa 900 caracteres e overlap 150. Nomic-embed-text é utilizado tanto na ingestão quanto na consulta. Chroma tem coleção vinculada ao hash da base e ativação após ingestão completa. Busca top-k=4, com distância de cosseno máxima 0,55 como ponto inicial. Distância não é score de qualidade. A geração usa ChatOllama com prompt versionado e contrato independente do operacional. Cada afirmação exige trecho literal recuperado e fonte existente. Não há garantia semântica universal contra alucinação.

3. Comparativo antes/depois

Item	Sprints 1/2 (versão original)	Sprint 04 (RAG avaliado)
Scores por iteração	N/D - sem medição original verificável	Coleta inicial GPT-OSS v1/v2: F 0,9231 / 1,0000; R 0,7626 / 0,7893. Coleta inicial e revalidação de 21/10 na próxima página.
Qualidade do contexto recuperado	N/D - artefato RAG original não disponível	Fonte esperada recuperada em 13/13 casos respondíveis. Proxy de cobertura; não comprova precisão semântica de cada trecho.
Citação de fonte	Prompt histórico; sem prova documental executável	Documento/página/seção e trecho validados, exibidos na interface.

Avaliação e limitações

gpt-oss:120b / v1: faithfulness 0.9231 (13/13), relevância 0.7626 (13/13); status esperado 24/24; falhas 0; fonte esperada recuperada 13/13.

gpt-oss:120b / v2: faithfulness 1.0000 (13/13), relevância 0.7893 (13/13); status esperado 24/24; falhas 0; fonte esperada recuperada 13/13.

gemma4:31b / v1: faithfulness 0.9487 (13/13), relevância 0.7960 (13/13); status esperado 24/24; falhas 0; fonte esperada recuperada 13/13.

gemma4:31b / v2: faithfulness 0.9444 (12/13), relevância 0.7062 (13/13); status esperado 23/24; falhas 1; fonte esperada recuperada 13/13.

gemma4:31b: variação de faithfulness N/A (cobertura diferente); variação de relevância -0.0897; sem ganho comprovado; regressão registrada.

gpt-oss:120b: variação de faithfulness +0.0769; variação de relevância +0.0266; ganho nas duas métricas.

RAGAS 0.4.3, juiz GPT-OSS 120B; uma repetição por condição. Scores não equivalem a revisão humana nem comprovam significância. Relevância fim a fim é zero em pergunta respondível sem resposta. Faithfulness é N/A nesse caso. Geração usa cloud e embeddings Nomic locais, permitidos e recomendados pelo professor conforme relato de Miguel em 15/10/2026. O HTTP 401 cloud anterior é evidência histórica, sem pendência de migração.

Revalidação independente de 21/10/2026 (resultados anteriores preservados):
gemma4:31b / v1: F 0.9615 (13/13), R 0.7815 (13/13); status 24/24; falhas 0.
gemma4:31b / v2: F 0.8974 (13/13), R 0.7233 (13/13); status 24/24; falhas 0.
gpt-oss:120b / v1: F 1.0000 (13/13), R 0.7928 (13/13); status 24/24; falhas 0.
gpt-oss:120b / v2: F 1.0000 (13/13), R 0.7970 (13/13); status 24/24; falhas 0.
As coletas são reportadas separadamente, sem selecionar apenas os melhores resultados. Corpus e casos coincidem, mas o hash do pipeline difere entre datas; não atribuir essas diferenças somente ao prompt. A comparação v1/v2 é controlada dentro de cada coleta. Ver docs/resultados_rag_20261021.md e scores datados.

Testes locais em 21/10/2026: 44 testes aprovados, incluindo componentes, memória, validação, RAG, interface e comparador. Log: docs/testes_20261021_rede.txt. A tentativa inicial restrita por permissões de rede foi separada da execução válida.

4. Problemas encontrados e soluções

O validador operacional aceitava somente três fontes e comparava números com uma fixture. Solução: schema/validador documental separado, preservando regras antigas. O mock HTTP dos testes antigos informava consumo sem fonte e era rejeitado: a fixture foi corrigida para citar consumo_mensal. Documentos maliciosos podem tentar alterar regras: trechos suspeitos são excluídos, instruções ficam fora dos documentos e citações são conferidas. O manual GoodWe restringe reprodução pública: o PDF original fica local e ignorado pelo Git; base pública usa síntese curta e documentos acadêmicos claramente identificados.

5. Equipe e atualizações

Turma 1CCPI. Miguel Piedade - RM 572445: implementação das melhorias desta etapa, integração RAG, interface, testes e documentação, com apoio de IA. As contribuições das etapas anteriores permanecem no histórico do projeto (Arthur de Oliveira - RM 568986; Rafael Zani Gizzi - RM 569033).

Reprodução e entrega

Repositório: https://github.com/Zanizada/chargewise-ai-3.0. Instalar requirements-sprint04-lock.txt em Python 3.12, configurar .env local, preparar Nomic local e baixar o manual conforme app/README.md; executar python -m src.rag.ingest e iniciar Streamlit. Protocolo e testes estão em evals/. Entrega prevista para 23/10/2026. Duas versões RAG v1/v2 e a melhoria medida atendem à interpretação confirmada por Miguel em 21/10; não é necessária uma v3 apenas para cumprir contagem de iterações.